

# 零样本多光谱学习：重新构想用于遥感应用的通用多模态 Gemini 2.5 模型

谷歌 DeepMind t 谷歌研究

## 摘要

多光谱影像在多种遥感应用中发挥着至关重要的作用，包括土地利用分类、环境监测和城市规划。这些影像之所以得到广泛应用，是因为其额外的光谱波段与地表的各类物理物质——如冰、水和植被——具有高度相关性。这使得对目标的识别更加精准。此外，来自“哨兵-2”和“陆地卫星”等任务的多光谱影像公开可用，进一步提升了其价值。目前，对这类数据的自动分析主要依赖于专为多光谱输入训练的机器学习模型，而这些模型的训练和维护成本高昂。另外，尽管多光谱数据为遥感领域提供了巨大便利，但它们却无法与功能强大的通用型多模态大模型协同使用。后者虽然能够解决诸多视觉问题，却无法理解专门的多光谱信号。

为此，我们提出了一种无需训练的方法，该方法仅以零样本模式引入新的多光谱数据作为输入，供仅基于 RGB 输入训练的通用多模态模型使用。我们的方法充分利用了多模态模型对视觉空间的理解，旨在使其

能够适应此类空间的输入，并将领域特定信息以指令形式注入模型中。我们以 **Gemini2.5** 模型为例验证了这一思路，并观察到该方法在土地覆盖与土地利用分类等热门遥感基准测试中取得了显著的零样本性能提升，同时证明了 **Gemini2.5** 模型对新输入的轻松适配能力。这些结果凸显了地理空间专业人员的潜力：即使面对非标准的专用输入，他们也能轻松借助诸如 **Gemini2.5** 之类的强大多模态模型，加速自身工作进程，充分受益于这些模型丰富的推理能力和上下文理解能力，而这一切都建立在专门传感器数据的基础之上。

## 1 引言

大型多模态模型（**LMM**）经过多种任务的训练，可作为通用型学习器。它们是强大的视觉理解工具，其泛化能力超越了训练数据范围，往往在许多未曾见过的任务中展现出令人惊叹的性能。遥感应用可充分利用这类大型通用型、与任务无关的模型所具备的广泛视觉理解能力。然而，大多数通用型多模态模型仅支持 **RGB** 图像输入，不适用于其他输入格式或模态，例如多光谱或其他类型的数据——而这些正是遥感领域常见的输入形式，通常可从 **Sentinel-2** 和 **Landsat** 等传感器获取。与此同时，遥感的多传感器输入非常有价值，因为它们能提供互补信息，例如，不同类型的输入可从不同角度看待同一数据。 **RGB + 新型多光谱输入 双子座零样本提示**




Figure 1: We demonstrate here how a generalist Gemini2.5 multimodal model, when queried Zero-Shot and without any training on unfamiliar multi-spectral inputs, can be adapted to process these inputs. This improves Gemini’s already strong performance on standard remote sensing tasks and extends its applicability to more Remote Sensing tasks which often require specialized models.

例如，多光谱波段能够捕捉更多频率信息，从而探测地表材料属性的多个方面。通过整合多种传感器，可以获得更准确、更详尽的响应；而单独的传感器，比如 **RGB** 传感器，则存在盲区和局限性。一种常见的做法是训练针对特定领域的基础模型[1, 2, 3, 4]，这些模型专门用于输入诸如 **RGB**、**NIR** 和 **SWIR** 通道等特定传感模态的数据。这类模型往往模仿大型多模态模型的架构，但它们是在一组针对特定传感器的数据上进行训练的——这一过程成本高昂，且需要收集领域专用数据，而这对于遥感应用而言并非易事。此外，新的输入传感器及其输入规格可能会随时间变化，这使得支持这类专业基础模型变得困难。例如，数据采集高度依赖于特定传感器，而这些传感器可能与先前或后续的传感器不兼容：新一代传感器可能扩展了输入数量，或者生成的数据在质量上与之前的不同甚至更高；此外，还可能出现新型传感器。因此，理想的多模态模型不应因输入源的每次新变化而重新训练。这些模型应具备较强的鲁

棒性，能够适应更新或不同的数据采集方式，并能轻松适配具有相似但并不完全相同的输入集的传感器。但是，我们如何在无需额外训练或微调的情况下，利用这些通用多模态模型来完成特定任务呢？我们提出了一种方法：重新利用通用多模态模型，以理解全新且未知的输入传感模态。这一方法充分利用了通用模型对视觉数据的理解能力，以及其对输入相关详细而具体指令的解读能力。整个过程完全无需任何训练或模型调整。其核心思想是：将新输入表示为伪图像输入，并为每一种伪图像配上详尽的文本描述，明确说明该输入的视觉表现所代表的具体含义（图 1）。例如，对于包含 12 个可能波段的多光谱输入，我们生成若干伪彩色图像，其中一些通常代表近红外、短波红外、归一化差异水分指数等，另外还有一些则是全新的波段组合。尽管这些伪图像并非真实图像，但模型的视觉空间仍能轻松理解它们。与此同时，我们通过一段解释性的详细文本提示，说明每张伪图像的生成方式——包括所选用的各个波段，以及每个波段在物理空间中可能测量的内容；此外，我们还进一步阐释这些图像的语义意义，比如“指示水分的存在”，或“反映绿色植被状况”。我们的方法充分挖掘并利用了通用大语言模型固有的强大视觉表征能力，同时以一种有助于特定应用场景的方式对其进行解读。这使得通用大语言模型在遥感应用中变得更加灵活多样、实用高效。我们以 **Gemini2.5** 模型[5]为例验证了这一思路。在完全零样本设置下，我们发现该模型对多光谱输入表现出强劲的性能，不仅大幅提升了零样本任务的表现，还达到了新的最先进水平（**SOTA**）。这些结果表明，大型通用多模态模型能够轻松地适应来自全新输入传感器的数据，从而在无需额外训练的情况下显著提升其性能，并进一步扩大其在遥感领域中更多任务的应用范围。 2 先前的工作

多模态基础模型在遥感领域得到了广泛应用[6]：这些模型专门使用遥感数据进行训练，以针对各类遥感应用。例如，**Remote-CLIP**[7]、**SkyCLIP**[8]和 **RS-CLIP**[9]都是常用的模型。另一种常见方法是构建特定领域的基础模型，即在已有的多模态基础模型基础上进行微调，所用数据专为遥感任务设计，或对遥感专用的基础模型进行预训练，如[10, 11, 12, 7, 8, 9, 6, 13, 14, 15, 16]所示。此外，还有一些研究提出了轻量级微调或适配的变体方法，例如[17]。不过，上述提及的遥感模型均仅适用于 **RGB** 图像域。为多光谱或多元传感器遥感数据构建基础模型[11,1,2, 18,19, 20,3, 21,22,23]同样大有裨益，尽管由于输入数据种类繁多，这一任务更具挑战性。**SatMAE**[1]提出了一种针对预训练遥感模型的专门扩展方案，该方案特别采用多光谱影像进行预训练。**Prithvi** 系列模型[2]则开发了以蓝、绿、红、窄近红外、短波红外 1 和短波红外 2 作为输入通道的基础模型。**SkySense**[11]提出了一种可同时处理 **RGB**、多光谱以及时间序列输入的模型。在[24]中，作者提出通过按分辨率对

多光谱数据的各个波段进行分离来开展训练。他们展示了以下结果：**M1** 分辨率为 **60×60** 米（多光谱波段 **1、9**），**M2** 分辨率为 **20×20** 米（波段 **5、6、7、8A、11、12**），**M3** 分辨率为 **10×10** 米，其输入包括 **RGB** 和近红外（**NIR**）波段。跨多光谱（**Sentinel-2** 与 **Sentinel-1**）输入的联合训练显示出更稳健的性能[25]。此外，还有一些基础模型专注于整合高光谱影像丰富的传感能力。例如，**SpectralGPT**[3]提出了一种基于三维广义 **Transformer** 的光谱基础模型。**HyperSIGMA**[4]则提出了一种稀疏注意力学习方法，以优化高光谱输入中的光谱空间特征提取。尽管这些基础模型在输入模态上更加全面，但在新增输入通道方面却缺乏灵活性。另外，训练多光谱或高光谱模型是一项资源消耗极为巨大的任务。相比之下，我们的工作利用的是通用型（基于 **RGB**）的大规模多模态模型，这些模型并不一定专用于遥感领域，无论是在预训练数据还是输入模态方面均如此。我们证明，像 **Gemini 2.5** 这样的多模态模型能够以零样本方式灵活地适应各种全新的、不熟悉的多光谱输入——也就是说，完全无需进行任何模型训练或调整。另一种方法是从大量遥感数据中学习语义上有意义的嵌入表示。遥感嵌入将预测任务视为一个两步过程：首先进行特征提取，即将多源传感器输入转化为经过学习得到的紧凑特征或嵌入表示；然后通过回归步骤，将这些嵌入表示与各任务对应的输出或标签相联系，例如 **MOSAICS** [26]、**SatlasPretrain** [10]、**EarthPT** [12]、**S2Vec** [27]、**AlphaEarth Embeddings** [28]。这些特征能够整合多种输入传感器，特别适用于聚类、进一步微调以及低样本量学习场景。然而，与我们的模型相比，它们在零样本设置中的应用并不那么便捷。

### 3 多传感器零样本推理

通用多模态模型是在从网络上收集的图像上进行训练的。因此，它们在零样本设置下对自然图像的表现相当出色。然而，它们无法理解其他类型的输入，例如常用于遥感领域的多光谱输入。在本节中，我们展示了如何将这些模型适配到其他传感模态，同时仍能实现零样本推理，且无需重新训练这些模型。

我们提出了一种针对全新且陌生输入的简单适配方法，以及一种专门的信息提示，用于解释输入生成的过程。借助这一方法，我们能够轻松地将一个通用的多模态模型转变为一个能够理解和出色处理新型多传感器数据的模型（图 1）。其核心思想是：以多种方式组合多光谱输入，并将其表示为图像或伪图像形式；同时，针对每种输入，通过提供详尽的提示——即专门描述输入视觉表现所代表内容的文字说明——来为其赋予明确的上下文语境。例如，对于包含 **12** 个可能波段的多光谱输入，我们生成了一系列伪彩色图像，这些图像通常代表近红外、短波红外、归一化差异植被指数（**NDMI**）等，它们在遥感任务中十分常见且颇具帮助。图 2 展示了基于 **BigEarthNet**[29]数据集从不同

多光谱波段生成的伪图像输入示例，图 3 则展示了基于 **EuroSat[30]**数据集的类似示例。上述新生成的图像将作为模型的输入。随后，我们通过一段描述性且详尽的提示语，说明每张图像的生成方式——即包含了哪些波段，以及每个波段在物理空间中可能测量的内容；同时，我们还会借助文本提示对这些图像进行解读。这样一来，多光谱输入模态仍可被表示为图像输入，从而便于通用型多模态模型理解，形成一种非常适合图像表达的格式。此外，文本提示还提供了有关新输入的必要信息与背景 **context**。例如，我们可以在提示语中列出输入传感器的信息：这些图像由选取 **Sentinel-2** 卫星的不同波段生成。各波段的具体信息如下：

- **1. B02 : 10 米分辨率的蓝色波段**
- **2.B03 : 10 米分辨率的绿色波段**
- **3.B04 : 10 米分辨率的红色波段**
- **4. B05 : 红边波段（中心波长 704.1 纳米），20 米分辨率**
- **5. B06 : 红边波段（中心波长 740.5 纳米），20 米分辨率**
- **6. B07 : 红边波段（中心波长 782.8 纳米），20 米分辨率**
- **7.B08 : 10 米分辨率的近红外波段**
- **8. B8A : 20 米分辨率的窄 NIR 波段**
- **9.B01 : 60 米分辨率的沿海气溶胶带**
- **10. B09 : 60 米分辨率的水汽波段**
- **11. B11 : 短波红外波段（中心波长 1613.7 纳米），20 米分辨率**
- **12. B12 : SWIR 波段（中心波长 2202.4 纳米），分辨率为 20 米。**


利用这些信息，我们可以进一步描述提示中的输入内容，如下所示（请参阅附录以获取完整提示）：

- 第一张图像为使用 **B04**、**B03** 和 **B02** 波段生成的 **RGB** 图像。
- 第二张图像为利用 **B08**、**B04** 和 **B03** 波段生成的假彩色合成图像。
- 第三张图是 **NDVI** 图像，它采用 **B08** 和 **B04** 波段生成，使用了红色、黄色和绿色三种颜色的渐变色图。
- 第四张图像是 **NDWI** 图像，其值范围为 **-0.8** 至 **0.8**，并采用线性变化的颜色映射 **[(1,1,1),(1,1,1),(0,0,1)]**。
- 第五张图像为利用 **B8A** 和 **B11** 波段生成的 **NDMI** 图像，其颜色映射线性变化为 **[(1, 0,0),(0, 1,0),(0,0,1)]**。

- 第六张图像为使用 **B8A** 和 **B12** 波段生成的 **NDMI** 图像，其颜色映射线性变化为 $[(1, 0, 0), (0, 1, 0), (0, 0, 1)]$ 。

这种方法充分利用了通用大语言模型固有的强大视觉表征能力，同时以一种有助于当前任务的方式解读新的视觉输入，并针对遥感应用的输入进行了专门化处理。







### 3.1 实施细节

为便于理解，我们在此除了标准的 RGB 输入外，还额外生成了五张伪图像输入。它们分别是：1) 利用 **Bo8**、**Bo4** 和 **Bo3** 波段生成的假彩色合成图像；2) 使用 **Bo8** 和 **Bo4** 波段生成的 **NDVI** 图像；3) **NDWI** 图像；4) 使用 **B8A** 和 **B11** 波段生成的 **NDMI** 图像；5) 使用 **B8A** 和 **B12** 波段生成的 **NDMI** 图像。必要时会应用颜色映射。在生成真彩色图像和假彩色合成图像（即第一张和第二张图像）时，我们会对每个波段进行归一化处理，使输入值处于 $[0, 1]$ 的范围内。随后，我们将这些归一化后的值缩放到 $[0, 255]$ 的范围，再将各波段叠加在一起，保存为 **RGB** 图像。

## 4 个实验

### 4.1 在 **BigEarthNet** 上使用多光谱输入的零样本结果

我们首先在流行的 **BigEarthNet** 数据集[29]上展示了所提出方法的性能。该数据集是一个土地覆盖分类数据集，提供了 **12** 个多光谱波段。这是一个多标签数据集，意味着每个样本可以同时被标注为多个类别。因此，评估该数据集的主要指标是 **F1** 指标，这也与文献[31]中的性能报告保持一致。我们还报告了精确率和召回率数值，以深入理解这两个指标及其对最终 **F1** 指标的贡献。此外，由于该数据集为多标签数据集，我们在模型输入时明确提示：模型的输出可能包含多个类别。我们并未对模型的输出类别数量加以限制。具体提示内容请参见附录。

| Model                                | F1           | Prec |
|--------------------------------------|--------------|------|
| Gemini2.5 with RGB                   | 0.388        | 0.5  |
| Gemini2.5 with Multi-Spectral (Ours) | <b>0.429</b> | 0.5  |

Table 1: BigEarthNet land cover classification Zero-Shot results (multimodal). The base multimodal model is used without modifications (Gemini 2.5). The F1. The gain realized from multi-spectral inputs is significant by **+0.04** in F1 across all classes.

表 1 : **BigEarthNet** 土地覆盖分类零样本结果（多标签、多类别）。所用基础多模态模型未经任何修改（**Gemini 2.5**）。主要性能指标为 **F1** 分数。利用多光谱输入带来的增益显著，**F1** 分数提升**+0.04**。分类共涵盖 **43** 个类别。

| Model                                | F1           | Prec |
|--------------------------------------|--------------|------|
| Gemini2.5 with RGB                   | 0.414        | 0.5  |
| Gemini2.5 with Multi-Spectral (Ours) | <b>0.453</b> | 0.5  |
| GPT-4V [31]                          | 0.38         | 0.5  |
| Qwen-VL-Chat [31]                    | 0.40         | 0.5  |
| InstructBLIP-FLAN-T5-xxl [31]        | 0.02         | 0.5  |
| InstructBLIP-Vicuna-13b [31]         | 0.01         | 0.5  |
| LLaVA-v1.5 [31]                      | 0.39         | 0.5  |

Table 2: BigEarthNet land cover classification Zero-Shot results (multimodal). The base multimodal model is used without modifications (Gemini 2.5). The F1. The gain realized from multi-spectral inputs is about **+0.04** in F1 across all classes. At the bottom, we compare to SOTA Zero-Shot results on the dataset. We achieve a **+0.053** gain in F1 over the best SOTA results.

表 1 展示了所提出的多光谱方法相较于仅使用 **RGB** 方法所获得的提升。在这两种情况下，我们均报告了零样本性能，并采用相同的 **Gemini 2.5** 模型进行推理——该模型同时适用于 **RGB** 和多光谱输入。我们发现，多光谱输入带来了显著的性能提升，且无需任何额外的训练或适配即可实现。所报告的结果基于数据集的原始版本，其中包含 **43** 个目标类别。

由于原始类别中部分存在相当模糊且语义含义重叠的情况，我们提出了一种包含 **19** 个类别的新版本数据集。在表 2 中，我们展示了基于 **19** 个类别的 **BigEarthNet** 实验结果。在此版本中，原有的 **43** 个类别被合并为更少、语义

更清晰的类别，这一做法也已被文献[32,31]所采用。如表所示，所提出的方案在这一版本的数据集上表现稳定且优异，其改进幅度与之前版本基本一致。表 2（底部）展示了零样本结果与当前最先进（**SOTA**）零样本方法的对比。如所见，**Gemini 2.5** 在仅使用 **RGB** 图像的场景中已表现出非常强劲的性能。

| Model                                | Classification Accuracy |
|--------------------------------------|-------------------------|
| Gemini2.5 with RGB                   | 60.5                    |
| Gemini2.5 with Multi-Spectral (Ours) | 61.5                    |
| CLIP [33] (CLIP-ViT L/14-336px)      | 58.5                    |
| CLIP [33] (CLIP-ViT L/14)            | 58.5                    |
| ZLaP [34] (Inductive inference)      | 60.5                    |

Table 3: Zero-Shot classification on the EuroSat benchmark. As seen, inference-only multi-spectral inputs performs best. We further report results of ZLaP which uses **Inductive Zero-Shot inference**, meaning it uses unlabeled examples, but without labels. Our approach, which is Zero-Shot only,

| Model                    | F1    | Precision |
|--------------------------|-------|-----------|
| RGB only                 | 0.406 | 0.560     |
| RGB + NDVI               | 0.415 | 0.509     |
| RGB + NDVI + NDWI        | 0.437 | 0.535     |
| RGB + All Multi-Spectral | 0.462 | 0.557     |
| RGB only                 | 0.410 | 0.533     |
| RGB + NDVI               | 0.448 | 0.548     |
| RGB + NDVI + NDWI        | 0.442 | 0.538     |
| RGB + All Multi-Spectral | 0.479 | 0.565     |

Table 4: Ablation results with adding NDVI and NDWI channels. The results are from the BigEarthNet multi-class multi-label benchmark, conducted on a subset of the dataset for land cover classification. Top: results with 43 classes, Bottom: results with 19 classes.

与功能强大的其他模型相比，其性能通过所提出的多光谱方法得到了进一步提升。 **4.2 多光谱输入下的零样本结果 EuroSat**

我们进一步评估了我们在流行的 **EuroSat** 土地利用分类基准[30]上采用的仅进行零样本推理的方法的性能。该基准使用的是高分辨率 **RGB** 影像，包含 **10** 个

类别，因此准确率是其主要性能指标。表 3 展示了实验结果。如表所示，采用我们提出的方法，我们在此基准上可实现+3%的准确率提升。

我们报告了该基准测试的零样本结果，以及当前最优的零样本结果，其中包括使用更多信息的 ZLaP 方法的结果。具体而言，ZLaP 采用的是归纳式零样本推理，即允许其使用数据集中的示例，但不提供标签。如所见，我们的方法优于当前最优方法，并且同样优于该方法。

尽管该数据集经过微调后表现优异，分类准确率高达 90%以上，但我们发现，零样本情境下的表现与之存在较大差距。这一现象的原因可能在于，某些类别在缺乏任何先验信息的情况下难以区分，例如“一年生作物”与“多年生作物”。若没有对每种作物外观特征的明确关联，模型便无法做出有效区分。而微调则能帮助机器学习模型将视觉输入与特定类别标签建立对应关系，这正是零样本情境下所不具备的。此外，我们还注意到，该数据集中存在一些噪声和标注错误的样本。尽管如此，我们仍观察到，采用我们的方法后，该基准任务的表现显著提升，准确率也有了明显改善，并且我们有望进一步缩小与完全微调后性能之间的差距。

### 4.3 消融

在表 4 中，我们展示了当多光谱输入发生变化时，该模型零样本性能的消融实验结果。该实验是在多标签多分类 **BigEarthNet** 数据集的一个较小子集上进行的（仅使用 **1000** 张图像）。如所见，添加所有多光谱图像后.....




Figure 4: Example results on the EuroSat data. The multi-spectral input improves the model's performance. **Top:** The answer provided by the proposed model with multi-spectral bands (9), which is the correct answer. Whereas the answer for the RGB-only model is 'Forest' (2) which the multi-spectral model identifies correctly. The model focusing on the green/blue and classifies it as a 'Sea lake' (10) which is incorrect.

表现最佳。其次，仅包含 **NDVI** 图像（与 **RGB** 图像一起）时的表现贡献了大部分这些提升，但其效果仍不如使用全部输入数据时的表现。

#### 4.4 可视化

图 4 展示了该模型在零样本条件下处理多光谱输入时的表现实例，以及与仅使用 **RGB** 图像相比所显现的差异。如图所示，额外的多光谱输入对于帮助模型理解仅凭 **RGB** 图像可能产生歧义的情况至关重要。例如，一幅包含森林的图像若呈现出深蓝或深绿色调，往往容易与水体——即海洋或海区——的图像相混淆，反之亦然。多光谱波段输入的存在有助于获得更准确的识别结果。具体而言，在上方展示的一幅河流图像中，仅使用 **RGB** 的模型预测为“森林”；而采用多光谱输入的本模型给出的答案则是“河流”，这正是正确答案。在下方，我



们看到一片森林区域的示例，多光谱模型成功地将其正确识别出来。相比之下，基准的仅使用 **RGB** 的模型却将其分类为“海湖”，这一判断显然是错误的，很可能是由于 **RGB** 图像中绿色和蓝色色调的混淆所致。图 5 进一步展示了两种模型意见一致的实例。图中展示了一张河流图像，两种模型均做出了正确判断。与图 4 顶部的图像相比，我们发现 **RGB** 输入已足够充分，因为颜色的歧义性要小得多。图 5 底部的图像则显示了两种模型均出现误判的案例。值得注意的是，无论是图 4 还是图 5 中的各个实例，仅凭 **RGB** 输入进行预测都可能颇具难度，因此多光谱输入对于实现更精准的理解至关重要。 **4.5 限制**

正如本文所指出的，我们正利用通用多模态模型理解视觉信息及其相关文本提示的能力，并提出通过丰富和调整模型输入，以拓展其多模态能力，使之能够处理更多种类的传感器数据。许多类型的航空地球观测数据，例如俯视遥感影像、多光谱、高光谱、热成像、激光雷达、雷达以及合成孔径雷达等输入，均符合视觉输入的要求，尤其适合于所提出的这种方法。然而，这一方法可能并不适用于其他类型的科学或地球观测数据源，因为其他类型的地球观测数据未必能很好地映射到视觉输入上。此外，我们还注意到，模型的输出可能会对文本提示及其提示顺序敏感；对提示进行一些细微调整，就可能导致不同的结果。




Figure 5: Example results on the EuroSat data where both models are correct. **Top:** An example of ‘River’ (9) which both models identify correctly. **Bottom:** A misclassification where the proposed model identifies this as ‘Annual crop’ (1), whereas the baseline identifies this as ‘lake’. The ground truth is ‘Pasture’ (6). As compared to Figure 4, it is more difficult to identify the only from RGB image.

## 5 结论与未来工作

遥感或航空地球观测模型在预训练阶段需要大量资源和数据集。尤其当这些模型需扩展以支持多种额外传感器，例如多光谱或深度信息时，这一需求尤为显著。我们提出利用已预先训练过的通用多模态模型——这些模型仅基于 **RGB** 图像进行训练——并在零样本设置下，实时地将它们适配到新的传感模态，例如多光谱图像。这种模态类型是这些模型在训练过程中从未见过的。为了说明这一理念，我们采用了一种通用的多模态模型——**Gemini 2.5**。该模型仅基于 **RGB** 输入进行视觉任务训练，在训练过程中并未使用任何专门的多光谱数据。我们证明，借助该模型强大的视觉理解能力及其提示生成功能，可以非常便捷地将其适配到这些全新的、未曾见过的输入和不熟悉的任务中。我们发现，**Gemini 2.5** 模型的表现得到了显著提升——而它本身在这些遥感任务中的表现已十分出色。

我们探索了来自多个多光谱波段的若干输入，并取得了成功成果。其他类型的传感器，例如合成孔径雷达（**SAR**）、深度传感器或热传感器等，也可自然地映射到视觉输入上，且无需对方法进行任何改动即可加以应用。不过，如前所述，有些传感器可能并不特别适合。这些探索工作我们将留待未来的研究中开展。此外，值得注意的是，在 12 个多光谱波段中，我们仅选取了五个示例图像组合，而实际上还可纳入许多其他更有价值的组合。这将进一步提升性能，且无需改变现有方法。

这项拟议工作的意义在于，这种易于使用的通用大型多模态模型的多模态适配方案，为难以泛化且成本高昂的多模态遥感训练提供了一种替代方案；同时，也避免了依赖于专门针对遥感的、成本高昂且难以持续



支持的独立训练。相反，所提出的方案充分利用了更为通用的预训练资源。

## 参考文献

[1] 宗叶珍，萨马尔·卡纳，孟晨林，帕特里克·刘，埃里克·罗齐，何宇彤，马歇尔·伯克，大卫·B·洛贝尔，以及斯特凡诺·埃尔蒙。**SatMAE**：用于时空及多光谱卫星图像的预训练 **Transformer**。载于爱丽丝·H·欧、阿莱克·阿加瓦尔、丹妮尔·贝尔格雷夫与京炯曹主编，《神经信息处理系统进展》，**2022** 年。

[2] 约翰内斯·雅库比克、苏吉特·罗伊、**C. E.** 菲利普斯、保罗·弗拉卡罗、丹尼斯·戈德温、比安卡·扎德罗兹尼、丹妮拉·施瓦尔茨曼、卡洛斯·戈梅斯、加比·尼尔耶西、布莱尔·爱德华兹、木村大纪、娜奥米·西穆姆巴、林松楚、**S.** 卡蒂克·穆卡维利、黛维亚尼·兰布哈特、卡马尔·达斯、兰吉尼·班加罗尔、达里奥·奥利维拉、米哈尔·穆什津斯基、库马尔·安库尔、穆图库马拉恩·拉马苏布拉马尼安、伊克莎·古隆、萨姆·哈拉吉、韩熙（史蒂夫）李、迈克尔·塞西尔、玛丽亚姆·艾哈迈迪、法特梅·科尔迪、哈梅德·阿勒莫哈马德、马尼尔·马斯凯、拉古·甘蒂，

科米·韦尔德马利亚姆与拉胡尔·拉马钱德兰。面向通用地理空间人工智能的基础模型。预印本可于 **arXiv** 获取：**2310.18660**，**2023** 年 **10** 月。

[3] 洪丹凤、张冰、李旭阳、李宇轩、李晨宇、姚静、横谷直人、李浩、佩德拉姆·加米西、贾秀萍、安东尼奥·普拉萨、保罗·甘巴、乔恩·阿特利·本尼迪克特松和乔塞琳·沙努索。**Spectralgpt**：光谱遥感基础模型。载于 **IEEE TPAMI**，**2024** 年。

[4] 王迪、胡美琪、金瑶、苗玉春、杨佳琪、徐一楚、秦晓蕾、马佳琪、孙玲玉、李晨星、傅川、陈鸿瑞轩、韩承熙、横谷直人、张静、徐敏强、刘林、张乐飞、吴辰、杜波、陶大成、张良培。**Hypersigma**：高光谱智能理解基础模型。载于 **IEEE TPAMI**，**2025** 年。

[5] 双子座团队。双子座 **2.5**：以先进推理、多模态、长上下文及下一代代理能力推动前沿发展。载于 **arxiv.org/abs/2507.06261**，**2025** 年。

[6] 陆思琪、郭俊林、詹姆斯·R·齐默-多芬尼、乔丹·M·尼乌斯马、王晓、帕克·范瓦肯伯格、史蒂文·A·韦恩克和霍元凯。遥感中的视觉基础模型：综述。载于 **arxiv:2408.03464**，**2024** 年。

[7]刘凡、陈德龙、关张庆云、周晓聪、朱家乐、叶巧琳、傅立勇、周军。

**RemoteCLIP**：一种用于遥感的视觉语言基础模型。载于《**IEEE 地球科学与遥感汇刊**》（**TGRS**），**2024** 年。

[8]王哲诚、拉贾尼·普拉巴<sup>1</sup>、黄天元、吴嘉俊和拉姆·拉贾戈帕尔。

**Skyscript**：一个用于遥感的大规模且语义多样的视觉-语言数据集。载于 **AAAI**，**2024** 年。

[9]李翔、文聪聪、胡元、周楠。**Rs-clip**：基于对比视觉语言监督的零样本遥感场景分类。载于《国际应用地球观测与地理信息学杂志》，**2023** 年。

[10]法文·巴斯塔尼、派珀·沃尔特斯、里特维克·古普塔、乔·费迪南多和阿尼鲁达·肯巴瓦伊。**Satlaspretrain**：用于遥感图像理解的大规模数据集。载于 **ICCV**，**2023** 年。

[11]郭欣、劳江伟、党波、张颖颖、于蕾、茹立祥、钟立恒、黄子源、吴康、胡定翔、何慧梅、王健、陈京东、杨明、张永军、李延生。**Skysense**：一种面向地球观测影像通用解译的多模态遥感基础模型。载于 **CVPR**，**2024** 年。

[12]迈克尔·J·史密斯、卢克·弗莱明和詹姆斯·E·吉奇。**Earthpt**：一种用于地球观测的时间序列基础模型。载于 **arxiv:2309.07207**，**2023** 年。

[13]卡蒂克·库克雷贾、穆罕默德·S·丹尼什、穆扎马尔·纳西尔、阿比吉特·达斯、萨尔曼·汗和法哈德·S·汗。**Geochat**：用于遥感的基于实地的大规模视觉语言模型。**2024** 年。

[14]科罗拉多·J·里德、里特维克·古普塔、舒凡·李、萨拉·布罗克曼、克里斯托弗·冯克、布莱恩·克利普、库尔特·凯乌策、萨尔瓦托雷·坎迪多、马特·于滕达勒和特雷弗·达雷尔。**Scale-mae**：一种具有尺度感知的掩码自编码器，用于多尺度地理空间表征学习。**ICCV**，**2023** 年。

[15]马蒂亚斯·门迪埃塔、博兰·韩、邢健·石、易·朱和陈晨。通过持续预训练迈向地理空间基础模型。**ICCV**，**2023** 年。

[16]李泰京、车金刚、徐俊勋。面向遥感图像的十亿级基础模型。**IEEE 地球观测与遥感精选主题期刊**（**IEEEJ-STARS**），**2023** 年。

[17]伊雷姆·乌尔库、O. 奥兹古尔·坦里奥维尔和埃尔德姆·阿卡金迪乌兹。

**Lora-nir**：面向近红外遥感图像的视觉变换器低秩适配方法。载于 **IEEE 地球科学与遥感快报**，**2024** 年。

[18] 达米安·伊巴菲斯、鲁本·费尔南德斯-贝尔特兰、菲利贝托·普拉和直树·横谷。用于高光谱图像分类的掩码自编码光谱-空间变换器。**IEEE 地球科学与遥感汇刊**，**2022** 年。

[19] 洪丹凤、韩竹、姚静、高连茹、张冰、安东尼奥·普拉萨和乔塞琳·沙努索。**Spectralformer**：用 **Transformer** 重新思考高光谱图像分类。**IEEE 地球科学与遥感汇刊**，**60**：1-15，**2022** 年。DOI：**10.1109/TGRS.2021.3130716**。

[20] 利努斯·谢本赖夫、迈克尔·莫默特和达米安·博思。用于高光谱图像分类的掩码视觉 **Transformer**。**IEEE/CVF 计算机视觉与模式识别研讨会 (CVPRW)**，**2023** 年。

[21] 安东尼·富勒、科琳·米拉德和詹姆斯·R·格林。**Croma**：基于对比雷达-光学掩码自编码器的遥感表征。**2023** 年。

[22] 吉约姆·阿斯特鲁克、尼古拉斯·贡蒂耶、克莱芒·马莱和洛伊克·朗德里厄。**Omnisat**：面向地球观测的自监督模态融合。**ECCV**，**2024** 年。

[23] 维沙尔·内敦加迪、安基特·卡里亚、斯特凡·厄姆克、塞尔日·贝隆吉、克里斯蒂安·伊格尔和尼科·朗：探索用于地理空间表示学习的多模态借口任务。**ECCV**，**2024** 年。

[24] 乌莎西·乔杜里、苏巴迪普·德伊、米哈伊·达特库、比普拉布·班纳吉和阿维克·巴塔查亚。利用多标签哨兵-2 **BigEarthNet** 档案进行跨波段检索与分类。载于《**IEEE 应用地球观测与遥感精选主题期刊**》，**2021** 年。

[25] 奥里·利尼亚尔、乔治·莱夫曼、约哈伊·布劳、纳达夫·谢尔曼、约塔姆·吉吉、沃伊切赫·希尔科和根纳迪·别廖兹金。通过混合模态掩码自编码增强遥感表征。载于 **2025** 年计算机视觉应用冬季会议 (**WACV**) 研讨会。

[26] 埃丝特·罗尔夫、乔纳森·普罗克特、塔玛·卡莱顿、伊恩·博利格、瓦伊沙尔·香卡尔、宫美·石原、本杰明·雷希特和所罗门·夏昂。一种可推广且易于获取的基于全球卫星影像的机器学习方法。载于 [arxiv.org/abs/2010.08168](https://arxiv.org/abs/2010.08168)，**2020** 年。

[27] 舒什曼·乔杜里、埃拉德·阿哈罗尼、钱德拉库玛丽·苏瓦尔纳、伊维尔·措格苏伦、阿卜杜勒·拉赫曼·克雷迪耶、卢春塔以及妮哈·阿罗拉。**S2vec**：一种自监督的地理空间嵌入。载于 <https://arxiv.org/abs/2504.16942>，**2025** 年。

[28] 克里斯托弗·F·布朗、米哈尔·R·卡兹米尔斯基、瓦莱丽·J·帕斯夸雷拉、威廉·J·拉克利奇、玛莎·萨姆·西科娃、陈辉·张、埃文·谢尔哈默、埃斯特法尼亚·拉赫拉、奥利维亚·怀尔斯、西蒙·伊柳申琴科、诺埃尔·戈雷利克、李慧·莉迪亚·张、索菲娅·阿尔吉、艾米丽·谢克特、肖恩·阿斯凯、奥利弗·吉南、丽贝卡·摩尔、艾莉克西斯·布库瓦拉斯和普希梅特·科利。**Alphaearth** 基金会：一种用于从稀疏标注数据中进行准确且高效全球制图的嵌入式场模型。载于 [arxiv.org/pdf/2507.22291](https://arxiv.org/pdf/2507.22291) , 2025 年。

[29] 根切尔·松布尔、马塞拉·查尔富兰、贝吉姆·德米尔和沃尔克·马克尔。**Bigearthnet**：用于遥感图像理解的大规模基准数据集。**IEEE** 国际地球科学与遥感研讨会 (**IGARSS**) , 2019 年。

[30] 帕特里克·赫尔伯、本杰明·比施克、安德烈亚斯·登格尔和达米安·博思。**Eurosat**：一种用于土地利用与土地覆盖分类的新数据集及深度学习基准。**IEEE** 地球观测与遥感应用专题期刊, 2019 年。

[31] 张晨辉与王雪儿。擅长标题生成，不擅计数：基于地球观测数据对 **GPT-4V** 的基准测试。载于 [arxiv.org/pdf/2401.17600](https://arxiv.org/pdf/2401.17600) , 2024 年。

[32] 根哲·森布尔、阿内·德瓦尔、特里斯坦·克罗伊齐格、菲利佩·马塞利诺、雨果·科斯塔、佩德罗·贝内维德斯、马里奥·卡埃塔诺、贝吉姆·德米尔和福尔克·马克尔。**Bigearthnet-mm**：用于遥感图像分类与检索的大规模多模态多标签基准数据集。**IEEE** 地球科学与遥感杂志, 2021 年。

[33] 亚历克·拉德福德、金钟旭、克里斯·哈拉西、阿迪蒂亚·拉梅什、加布里埃尔·戈赫、桑迪尼·阿加瓦尔、吉里什·萨斯特里、阿曼达·阿斯凯尔、帕梅拉·米什金、杰克·克拉克、格雷琴·克鲁格和伊利亚·苏茨克弗。从自然语言监督中学习可迁移的视觉模型。载于 **ICML** , 2021 年。

[34] 弗拉丹·斯托伊尼奇、扬尼斯·卡拉蒂迪斯和乔治·奥斯·托利亚斯。基于视觉语言模型的零样本分类中的标签传播方法。载于 **CVPR** , 2024 年。

## A 关于零样本提示示例的附加信息

我们在此提供用于多光谱输入的提示词，随后是仅使用 **RGB** 的提示词示例。  
第一个提示词示例适用于 **BigEarthNet**，最后一个则适用于 **EuroSat**。对于不同的基准测试，可用类别集合需要相应调整。由于 **BigEarthNet** 是一个多标签多分类数据集，我们要求提供多个答案，即通过添加“选择所有适用项”来实现；而在分类数据集（例如 **EuroSat**）中，则直接省略此选项。 **BigEarthNet** 多光谱输入提示：

说明：请根据以下 **6** 张同一场景的图像回答所提出的问题。这些图像由 **Sentinel-2** 卫星的不同波段生成。

乐队信息如下：

**1.B02**：10 米分辨率的蓝色带

**2.B03**：10 米分辨率的绿色波段

**3.B04**：10 米分辨率的红色波段

1.

**B05**：红边波段（中心波长 **704.1** 纳米），**20** 米分辨率

2.

3.

**B06**：红边波段（中心波长 **740.5** 纳米），**20** 米分辨率

4.

5.

**B07**：红边波段（中心波长 **782.8** 纳米），**20** 米分辨率

6.

**7.B08**：10 米分辨率的近红外波段

**8.B8A**：20 米分辨率的窄 **I NIR** 波段

**9.B01**：60 米分辨率的海岸 **1** 气溶胶波段

**10.B09**：60 米分辨率的水汽波段

1. **B11 : SWIR** 波段（中心波长 **1613.7** 纳米）七七 **20** 米分辨率

**12.B12** : 短波红外波段（中心波长 **2202.4** 纳米），**20** 米分辨率。第一张图像为使用 **B04**、**B03** 和 **B02** 波段生成的 **RGB** 图像。

第二张图像为利用 **B08**、**B04** 和 **B03** 波段生成的假彩色合成图像。

第三张 **i** 图像为 **NDVI** 图像，该图像采用 **B08** 和 **B04** 波段生成，使用了红色、黄色和绿色三种颜色的色标。第四张图是 **NDWI** 图像，其值范围为 **-0.8** 至 **0.8**，并采用线性变化的颜色映射，即 $[(1, 1, 1), (1, 1, 1), (0, 0, 1)]$ 。

第五张图像为利用 **B8A** 和 **B11** 波段生成的 **NDMI** 图像，其颜色映射以线性方式变化，范围为  $S[(1, 0, 0), (0, 1, 0), (0, 0, 1)]$ 。该图像用于识别湿润与干燥区域。

第六张图像为使用 **B8A** 和 **B12** 波段生成的 **NDMI** 图像，其颜色映射线性变化为 $[(1, 0, 0), (0, 1, 0), (0, 0, 1)]$ 。该图像用于识别湿润与干燥区域。

输出格式：以“(X)”的形式输出正确答案对应的选项编号，其中 **X** 为正确的选项序号（范围 **1** 至 **43**）。若有多个正确答案，请以相同格式用逗号分隔列出所有答案选项。例如，若正确答案是第 **11** 项和第 **3** 项，则输出“(1),(3)”。仅输出上述格式的选项编号，不要输出完整的答案文字或任何其他额外内容。问题：给定的图像属于以下哪个类别？选择所有适用的选项。可能的答案选项：

(1) 农林区

(2) 机场

(3) 与多年生作物相关的一年生作物

(4) 裸岩

(5) 海滩、沙丘、沙滩

(6) 阔叶林

(7) 烧焦的区域

(8) 沿海泻湖

(9) 复杂的栽培模式

(10) 针叶林

(11) 施工现场

(12) 连续的城市结构



- (13)**不连续的城市结构
- (14)**垃圾填埋场
- (15)**河口
- (16)**果树和浆果种植园
- (17)**绿色城市区域
- (18)**工业或商业单位
- (19)**内陆沼泽
  - (20)** 潮间滩涂
- (21)**土地主要用于农业，同时拥有大片天然植被；**(22)**矿产开采区
- (23)**混交林
- (24)**荒原与石南地
- (25)**天然草地 **(26)**非灌溉耕地
- (27)**活的树林
- (28)**牧场
- (29)**泥炭沼泽
- (30)**永久灌溉土地 **(31)**波尔塔雷亚斯
- (32)**稻田
- (33)**道路与铁路网络及其相关土地
- (34)**盐田
- (35)**盐沼
- (36)**硬叶植被
- (37)**海与洋
- (38)**植被稀疏的地区
- (39)**体育与休闲设施
- (40)**过渡性林地/灌木丛
- (41)**葡萄园
- (42)**水体

**(43)水道**

答案：

仅限 **RGB** 输入的 **BigEarthNet** 提示词

说明：请根据给定图片后的问题作答。输出格式：以“(X)”的形式输出正确答案对应的选项编号，其中 **X** 为正确的数字选项（范围 **1** 至 **43**）。若存在多个正确答案，请以相同格式用逗号分隔列出所有正确答案。例如，如果正确答案是选项 **1** 和选项 **3**，则输出“(1),(3)”。仅输出上述格式的选项编号，不要输出完整的答案文字或任何其他额外内容。

问题：给定的图像属于以下哪个类别？选择所有适用的选项。可能的答案选项：

**(1)** 农林区

**(2)** 机场

**(3)** 与多年生作物相关的一年生作物

**(4)** 裸岩

**(5)** 海滩、沙丘、沙滩

**(6)** 阔叶林

**(7)** 烧焦的区域

**(8)** 沿海泻湖

**(9)** 复杂种植模式

**(10)** 针叶林

**(11)** 施工现场

**(12)** 连续的城市结构

**(13)** 不连续的城市结构

**(14)** 垃圾填埋场

**(15)** 河口

**(16)** 果树和浆果种植园

**(17)** 绿色城市区域

**(18)** 工业或商业单位

- (19)内陆沼泽
  - (20) 潮间滩涂
- (21)土地主要用作农业，南部有大片天然植被
- (22)矿产开采地点
- (23)混交林
- (24)荒原与石南地
- (25)天然草地
- (26)未灌溉的耕地
- (27)活的树林
- (28)牧场
- (29)泥炭沼泽
- (30)永久灌溉土地
- (31)波尔塔雷亚斯
- (32)稻田
- (33)公路与铁路网络及其相关土地
- (34)盐场
- (35)盐沼
- (36)硬叶植被
- (37)海与洋
- (38)植被稀疏的地区
- (39)体育与休闲设施
- (40)过渡性林地/灌木丛
- (41)葡萄园
- (42)水体
- (43)水道

答案：

仅限 RGB 输入的 BigEarthNet 提示，19 个类别

说明：请根据给定图片后的问题作答。输出格式：以“(X)”的形式输出正确答案对应的选项编号，其中 **X** 为正确的数字选项（范围 **1** 至 **19**）。若有多个正确答案，请以相同格式用逗号分隔列出所有正确答案。例如，若正确答案是选项 **11** 和 **3**，则输出“(11), (3)”。仅输出上述格式的选项编号，不要输出完整的答案文字或任何其他额外内容。

问题：给定的图像属于以下哪个类别？选择所有适用的选项。可能的答案选项：

(1)农林区

## (19)城市结构

答案：

## 仅限 RGB 输入的 EuroSat 提示词

说明：请回答给定图片后提出的问题。

输出格式：以“(X)”的形式输出正确答案对应的选项编号，其中 **X** 为单标签分类任务的正确选项编号（**1** 至 **10**）。仅输出上述格式的选项编号，不要输出完整的答案文本或任何其他额外文字。问题：给定的图像属于以下哪个类别？可能的答案选项：**(1)**一年生作物 **(2)**森林 **(3)**草本植被 **(4)**公路 **(5)**工业 **(6)**牧场 **(7)**多年生作物 **(8)**住宅 **(9)**河流 **(10)**海湖 答案：

### B 数据集详情

本研究中的实验均采用仅评估的零样本方式进行。我们提供了所用数据集的详细信息。

**BigEarth** 数据集[29]包含 **59** 万张图像。主要输入图像的分辨率为 **120×120** 像素，最后两张图像的分辨率为 **60×60** 像素。这是一个多标签数据集，每张图像可有多于一个正确标签。该数据集共有 **43** 个类别。由于原始版本存在歧义，文献中常采用一个由 **19** 个类别组成的变体版本[32]。**EuroSat** 数据集[30]包含 **2.7** 万张图像，图像分辨率为 **64×64** 像素。该数据集共有 **10** 个类别。