

<https://doi.org/10.3799/dqkx.2023.043>



基于卷积神经网络的土体含水率智能识别

庞元恩, 王智诚, 李旭*, 杜赛朝

北京交通大学土木建筑工程学院, 北京 100044

摘要: 土体含水率是影响细粒土性质的主要因素. 土体表层含水率的快速识别是农业和岩土工程中智能监测和智能建造技术发展中的迫切需求. 为了克服传统含水率测量或监测方法无法满足土体表层含水率的实时无损监测的局限性, 特研发基于图像的含水率智能识别算法. 首先在实验室中收集了 4 种不同类别的土体、在不同含水率下的表面照片, 获得了超过 1 400 张图片的高质量样本库, 为机器学习模型构建奠定了数据基础. 然后采用经典的卷积神经网络对土体含水率图像数据集进行学习, 建立了土体含水率智能识别模型. 模型比选结果表明: 基于 ResNet34 架构的土体含水率识别模型效果最佳, 在测试集上的含水率预测平均误差约为 2%. 该模型初步满足了土体表层含水率的实时无损监测需求, 能够为农业和岩土工程中智能监测和智能建造技术发展提供重要手段.

关键词: 土体含水率; 深度学习; 卷积神经网络; 智能监测; 智能建造; 工程地质.

中图分类号: P581

文章编号: 1000-2383(2024)05-1746-13

收稿日期: 2023-02-10

Moisture Content Recognition Model of Unsaturated Soil Based on Convolutional Neural Networks

Pang Yuanen, Wang Zhicheng, Li Xu*, Du Saizhao

School of Civil Engineering, Beijing Jiaotong University, Beijing 100044, China

Abstract: The moisture content of the soil is the main factor affecting the quality of fine-grained soil. Rapid recognition of soil surface moisture content is an urgent need for developing intelligent monitoring and construction technology in agricultural and geotechnical engineering. In order to overcome the limitation that traditional water content measurement or monitoring methods cannot meet the real-time nondestructive monitoring of soil surface moisture content, an intelligent moisture content recognition algorithm based on the image is developed. Firstly, we collected surface photos of 4 different types of soils under different moisture contents in the laboratory and obtained a high-quality sample library of more than 1 400 pictures, which laid a data foundation for machine learning model construction. Then the classical convolutional neural network is used to learn the image dataset of soil moisture content, and the intelligent recognition model of soil moisture content is established. The model comparison results show that the model based on ResNet34 architecture has the best moisture content recognition effect, and the average error of moisture content prediction on the test set is about 2%. This model basically meets the requirement of real-time nondestructive monitoring of soil surface moisture content and can provide an essential means for the development of intelligent monitoring and construction technology in agricultural and geotechnical engineering.

基金项目: 国家重点研发计划资助项目(No.2022YFE0200400).

作者简介: 庞元恩(2002-), 男, 本科生, 主要从事机器学习在岩土工程应用等方面研究. ORCID: 0000-0003-0459-0215. E-mail: yuanenpang@gmail.com

* 通讯作者: 李旭, E-mail: cexuli2012@163.com

引用格式: 庞元恩, 王智诚, 李旭, 杜赛朝, 2024. 基于卷积神经网络的土体含水率智能识别. 地球科学, 49(5):1746-1758.

Citation: Pang Yuanen, Wang Zhicheng, Li Xu, Du Saizhao, 2024. Moisture Content Recognition Model of Unsaturated Soil Based on Convolutional Neural Networks. *Earth Science*, 49(5):1746-1758.

Key words: soil moisture content; deep learning; convolutional neural network (CNN); intelligent monitoring; intelligent construction; engineering geology.

0 引言

含水率是土的基本物理指标之一,对土体的强度、变形、导热性及稳定性有着至关重要的影响.精确快速测量土的含水率对边坡工程(倪九派等,2009;宋丙辉等,2017; Domínguez-Cuesta *et al.*, 2021; 雨德聪等, 2021)、农业生产(姚丽等, 2020; Zheng and Gao, 2020; 周川等, 2021)、隧道开挖等都具有重要意义.比如隧道开挖坍塌和挖方体边坡冲蚀破坏等现场失稳灾变问题,造成这些事故的一个重要原因就是土体含水率在降雨入渗、农田灌溉等后发生重大变化,从而诱发土地地质湿陷(周尚国, 2007; 王志良等, 2012).因此土体原位含水率的监测,在重大岩土工程的安全评估和农业生产中都存在着巨大的需求.

现阶段,土壤含水率的测定方法有:烘干法、电阻法、中子法、 γ -射线法、光纤传感器等(常丹等, 2014; 王大龙和舒英格, 2017; 赵宇飞和王长沙, 2017; 郭焘和于红博, 2018).烘干法利用土壤烘干前后的质量计算得到含水率,它是唯一可以直接测量土壤水分的方法,也是目前国际上的标准方法.但该方法操作繁琐,耗时低效,无法实时获取土壤含水率.电阻法是将两个电极埋入土壤,然后测得两个电极之间的电阻,进而得到土壤含水率.该方法不破坏土壤,成本低,且能实现实时测量.但存在滞后作用,测量范围小,灵敏度低的局限(常丹等, 2014);中子法与 γ -射线法都是利用微观粒子来测定土壤含水率,这两种方法精度高、速度快,但都存在对人体健康造成危害的缺陷;光纤传感器利用了光的反射、透射、偏振进行土壤热效应的观测,再进一步推导出土壤的含水率,该方法近年来发展迅速,但是尚存在精度不高,适应性不强的问题(Wang *et al.*, 2020).综上所述:目前的含水率测量或监测方法尚无法满足土体表层含水率的实时无损监测需求,是岩土工程和农业智能监测技术中亟需解决的关键问题之一.

近些年来,国内外学者尝试将机器学习算法应用于含水率识别问题.孙宇乐等(2020)先用数学方法对遥感图像进行处理得到与含水率有关的特征,再将其输入神经网络训练得到了含水率识别模型,

实现了土壤含水率动态变化规律的快速精确监测.侯晓丽等(2016)将多个气象学参数作为特征向量,基于人工神经网络(Artificial Neural Network, ANN)构建了土壤墒情动态预测模型,能够准确预测不同埋深条件下的土壤墒情分布情况. Cai *et al.* (2019)基于相关性分析选取输入变量,构建具有大数据拟合能力的深度学习回归网络(Deep Learning Regression Network, DNNR),在保证土壤水分数据趋势和数值预测精度的同时丰富输入特征.然而上述方法特征提取过程繁琐,检测尺度大,无法用于少量土样的含水率识别.

人工智能领域,卷积神经网络的迅速发展为此类问题的解决提供了新思路.自2012年 AlexNet (Krizhevsky *et al.*, 2017)夺得 ImageNet 分类冠军,深度卷积神经网络强大的图像识别能力受到越来越多的关注. Simonyan and Zisserman (2015)提出的 VGG 网络架构实现了神经网络的模块化设计,进一步提高了网络深度. Inception Net (Szegedy *et al.*, 2015)在保证精度的同时丢弃了全连接层,大大降低了过拟合的风险. He *et al.* (2016)提出的 ResNet 网络架构解决了深层网络的梯度消失问题,使得一千层超深网络的训练得以实现.在此基础上, Huang *et al.* (2016)提出 DenseNet 网络架构,进一步提高了识别精度.目前卷积神经网络已成功应用于图像分类(程国建等, 2021; Zhao *et al.*, 2021)、目标检测(Tian and Daigle, 2018; 黄晓红等, 2022)、语义分割(Fan *et al.*, 2022)、灾害监测(黄武彪等, 2022)等多个领域.

通过图像识别土体含水率的关键在于挖掘图片中土体表面颜色、裂缝及凹陷信息,建立其与含水率之间的关系. Zanetti *et al.* (2015)将单张含水率图片中若干像素对应的 RGB(图像的红、绿、蓝三通道)值作为输入,通过构建 ANN 实现了 3 种土样含水率的识别,预测值与真实值吻合较好.但严格控制光照以减少颜色相关噪音,条件苛刻,实际工程无法满足.张晗等(2023)直接将含水率图像输入卷积神经网络,实现了端到端的学习(end to end)(Chen *et al.*, 2018),识别过程大大简化.但所得模型只能实现特定含水率分类,无法用于含水率连续变化下的预测.




图 1 技术路线

Fig.1 Research route chart of this paper

综上所述,虽然机器学习为土体含水率的识别提供新的途径,但是目前尚没有成熟的含水率识别模型,亟需在这一问题上取得突破.为此,首先针对数据样本不足的问题,构建了多种土体、在不同压实度下、不同含水率下的表面图像数据集.然后采用经典的卷积神经网络(CNN)构建基于图像的含水率识别模型,并比较不同数据集划分方法、不同网络架构对含水率模型识别精度的影响.该模型能够实现土样含水率的快速无损识别,将是传统烘干法之外的一种高效补充手段.

1 数据采集与数据集构建

研究思路如图 1 所示,首先在实验室制得不同种类土在不同压实度下的试样,跟踪试样含水率下降过程并拍摄表面图像.接着对所得原图像进行剪裁、缩放等预处理以提高模型训练效率,按照不同种类土样混合与否得到混合数据集与分离数据集.通过对比同一网络在不同数据集的表现,以及不同网络在同一数据集的表现确定最佳数据集划分方法与最优网络架构.最后将离群样本定义为异常数据剔除,重新训练后得到最终含水率识别模型.

1.1 数据采集

1.1.1 材料及器具 数据收集过程所用的实验装置有:液压压实器、5.5 cm×5.5 cm×2 cm 塑料小盒、高度 2 cm 体积 60 cm³ 的环刀、电子秤、吹风机、真空饱和缸、4 608×2 176 分辨率相机、盆、搅拌勺、喷壶、滤纸、保鲜膜、热烘干机.用于构建数据集的土样类型有:延庆粉质黏土、兰州粉土、青海粉质黏土和标准砂,其基本性质如表 1 所示.

从机理上说:随着含水率的增大,土样表面的颜色、纹理和孔隙结构特征都会发生变化.土体含

表 1 土样基本性质

Table 1 Basic properties of each soil

土壤种类	比重 $G_s(\text{g}/\text{cm}^3)$	最优含水率 $w_o(\%)$	最大干密度 $\rho_d(\text{g}/\text{cm}^3)$
1. 延庆粉质黏土	2.73	16.50	1.80
2. 兰州粉土	2.71	14.81	1.78
3. 青海粉质黏土	2.68	15.50	1.75
4. 标准砂	2.65	11.56	1.82

水率越高,其颜色越深,光洁度越高,裂缝和凹陷越少.这些特征很多时候肉眼无法定量分辨.随着深度学习,尤其是卷积神经网络的快速发展.近年来图像识别模型获得了空前的成功,在文字、图片、人脸识别等领域,机器学习模型的效果远远超越了人类,获得了广泛的应用.因此通过科学合理的训练和学习,土样表面的颜色、纹理和孔隙结构特征有可能被机器学习模型准确提取,并进一步基于这些特征进行含水率的预测.

需要说明的是:深度学习模型的特征提取是隐式的,目前尚存在难以解释的局限性.我们无法明确确定深度学习模型提取的何种特征,只能通过预测效果来进行模型评价.

1.1.2 样品制作 级配、含水率、压实度是天然土体的主要变量.为了保证样本的多样性,特制备了多种不同土体、不同压实度、不同饱和度条件下的样本.本文使用的土体类型包括:延庆粉质黏土、兰州粉土、青海粉质黏土、标准砂.土体压实度范围为:0.85~1.00.土体饱和度范围为:0~1,共计拍摄了 1 410 样本的表面照片.

具体的制样方法如下:

(1) 按照预定压实度,用液压压实器(图 2a)将环刀取得的试样压实,制得压实




图2 粉质黏土等试样制备(环刀法)
Fig.2 Sample preparation for silty clay soil and other soils (cutting ring method)
a.液压实器; b.压实土样(青海粉质粘土)

土样(图 2b),放入真空饱和缸。
(2) 取出试样,拍摄其翻转与旋转后共 6 张图片,记录当前质量.继续暴露于空气一段时间以降低其含水率,然后用保鲜膜将试样包裹,养护时间为 24 h.重复此过程至含水率无明显降低。

(3) 测量试样干燥后质量,按照式(1)推得每次拍摄时含水率,作为数据集的标签。

$$w=\frac{m_k-m_d}{m_d-m_r}\times 100\%,$$

(1)

式中: w 是此时含水率,单位为%。 m_k 试样第 k 次拍摄后质量,单位为 g; m_d (g)为试样干燥后质量,单位为 g; m_r 为环刀质量,单位为 g。

标准砂不易用环刀制样,具体表现为饱和制样不易成功、风干过程不易养护、含水率变化过快、含水率较低后易脱落等,故改用小盒制样(图 3).小盒土样通过手动装满压实,没有严格控制干密度.由于无法使用饱和缸,先将砂土配制到较高含水率 $23\%\pm 1\%$ 再进行制样,之后用保鲜膜包裹养护.拍摄过程进行 4 次间隔为 90° 的旋转,不进行翻转,其他操作与前述过程相同.按照前述制样方法收集所得原数据集总结如表 2 所示。

1.2 数据集构建

1.2.1 数据预处理 原图(图 4a)分辨率为 $4\,608\times 2\,176$ (像素),大部分区域为与含水率无关的场地背景,不利于模型训练.假设含水率在二维平面分布较均匀,当所考虑区域足够大时,此区域含水率能代表土样含水率.以兰州粉土为例,具体做法是从每张原图中心截取 448×448 大小作为新的数据(图 4b)。

经过裁剪,4 种土样图片大小变为 448×448 ,各



图3 标准砂试样制备(“小盒”法)
Fig.3 Sample preparation for sandy soil (“small box” method)
a.小盒容器; b.标准砂土样

表 2 原数据集总结

Table 2 Summary of original dataset

土壤类型	压实度	平行样本数量(个)	照片数量(张)
延庆粉质黏土	1.00	2	156
	0.95	1	78
兰州粉土	1.00	2	216
	0.90	1	108
	0.85	2	216
青海粉质黏土	0.95	1	132
	0.90	1	132
	0.85	2	264
标准砂	-	4	108




图4 剪裁处理
Fig.4 Cutting processing

自按照 4:1 的比例随机划分为训练集与测试集.为了减小神经网络模型在训练过程中出现的过拟合等问题,对延庆粉质黏土、兰州粉土、青海粉质黏土的训练集与测试集进行扩增操作(图 5),对采集到的每一类图片通过水平翻转、水平颠倒、旋转 90° 、 270° 等处理进行数据增强,将每类含水率下的图片扩展至 8 倍数量,即数据集扩增 8 倍.由于拍摄标准砂样品时已经进行了间隔为 90° 的旋转拍摄,故只做水平翻转扩增,即数据集扩增 2 倍。

1.2.2 分离数据集构建 由于不同种类土存在较大差异,其表达含水率的特征既有个性又有共性,




图 5 数据扩增
Fig.5 Data augmentation

表 3 分离数据集总结

Table 3 Summary of separate dataset

土壤类型	训练集	测试集
延庆粉质黏土	1 497	375
兰州粉土	3 456	864
青海粉质黏土	3 379	845
标准砂	173	43

表 4 混合数据集总结

Table 4 Summary of mixed dataset

土壤类型	训练集	测试集
四种土	8 505	2 127

假设个性占比高于共性,则对每种土分别训练含水率识别模型的做法,优于对所有土训练一个含水率识别模型的做法.基于此假设,对每种土合并其不同压实度的平行试样得到分离数据集 (Separate dataset),如表 3 所示.

1.2.3 混合数据集构建 假设土壤表达含水率特征中个性占比低于共性,则对每种土分别训练含水率识别模型的做法,劣于对所有土训练一个含水率识别模型的做法.基于此假设,在分离数据集的基础上,将所有类型土合并得到混合数据集 (Mixed dataset),如表 4 所示.所收集的数据中不同土的含水率最大、最小值有所差异,含水率间隔为 1%~3%,土样样例图片及其对应含水率如图 6 所示,第一列为该类型土所收集数据中含水率最大值,最后一列为最小值,中间两列介于两者之间.

2 模型构建及训练

2.1 卷积神经网络简介

卷积神经网络是一种具有局部连接、权值共享等特点的深层前馈神经网络,擅长处理图像相关的机器学习问题,如图像分类、目标检测、图像分割等,是目前应用最广泛的模型之一.

卷积神经网络的基本结构大致包括以










名称	最大值	中间值		最小值
1.延庆粉质黏土	 29.31%		 9.05%	 1.70%
2.兰州粉土	 31.33%		 11.02%	 3.02%
3.青海粉质黏土	 33.94%		 12.18%	 2.18%
4.标准砂	 20.75%		 7.28%	 3.06%

图 6 各类型土样例展示
Fig.6 Samples display for each soil

下 4 大要素:

(1)卷积层:前面的卷积层提取图片上的边缘、线条和角等低级特征,后面的卷积层能够综合前面的卷积层提取到更复杂的特征(如图 7 所示,这里只是形象展示大致含义,并不一定完全符合卷积层提取到的信息).

(2)池化层:通常放在若干卷积层之后,将特征切成几个区域,取其最大值或平均值,得到新的、维度较小的特征.一方面降低了运算量,另一方面提高了模型泛化性.

(3)全连接层:对前面卷积、池化部分提取到的特征信息(如含水率图像的表面颜色、开裂情况等)进行综合分析,提高网络表达能力.

(4)输出层:即最后一个全连接层,输出网络预测结果.

2.2 模型网络架构介绍

过于简单的模型无法充分提取图片中的必要特征,过于复杂的模型容易发生过拟合,选择复杂度合适的模型是必要的.网络架构决定了模型复杂度,选取 5 种复杂度不同的网络架构:简单网络(结构如图 8a 所示),NiN(Lin *et al.*, 2014),VGG16(Simonyan and Zisserman, 2015), ResNet18 与 ResNet34(He *et al.*, 2016),比较在不同网络架构下训练出含水率预测模型的精度,确定最优网络架构.




图 7 卷积网络基本架构

Fig.7 Basic structure of convolutional neural network

所需预测的含水率为单个变量,在 NiN、VGG16、ResNet 系列基础上做出一些修改,具体做法是将 NiN 最后一个 NiN 块的输出通道数改为 1(如图 8b 所示),VGG16 和 ResNet 系列的全连接部分增加一个隐藏层,并将最后一层的输出个数改为 1(如图 8c 与 8d 所示)。

网络架构的复杂度取决于其中参数的数量,参数数量越多,网络架构越复杂,相应的模型的表达能力也更强,但同时也存在训练时间长、易发生过拟合等缺点。经修改后的各网络参数数量以及批量大小取 16 时,在分离数据集的青海粉质黏土上训练一轮耗时如表 5 所示。简单网络参数最少,训练速度最快。VGG16 参数最多,训练速度最慢。网络层数与模型表达能力相关,虽然 ResNet 系列具有与 VGG16 相当或更多的网络层数,但模型大小并未过

表 5 五种网络架构模型的复杂度与性能对比

Table 5 Complexity and performance comparison of five network architecture models

模型	模型大小 (MB)	训练速度 (s/epoch)
简单网络	6.49	13.59
NiN	32.33	20.57
VGG16	275.50	99.71
ResNet18	106.39	36.89
ResNet34	178.45	53.65

度增长,训练速度也高于 VGG16,这在一定程度上反映了该架构的优越性。

2.3 含水率预测模型构建

含水率预测模型的输入是某一含水率下的土样表面图像,标签是拍摄时刻的含水率。

确定最优网络架构的过程在分离数据集中样本量最大的兰州粉土上进行。模型训练过程采用相同超参数:优化器为 SGDM(momentum=0.9),学习率为 0.003,激活函数为 ReLU,批量大小为 16,损失函数为 HuberLoss。为在加速训练的同时尽可能避免因过度缩放造成的模型精度下降,输入神经网络前将图片由 448×448 缩放为 224×224 。即使是相同网络架构、相同数据集与超参数下,模型最后的收敛结果也会存在较大差异,为避免因偶然性造成结论不合理,采取五折交叉验证,即对每种数据集划分方法,保证其中训练集与测试集各自数量不变,进行 5 次划分。每一次分别训练模型,取 5 次模型预测平均值作为最后结果,后续“训练一个模型”指交叉验证所得模型的平均值。建模过程如图 9 所示。

2.4 评价指标

工程实际中,往往希望模型对所有土样的识别误差都在一个较小范围内,而不是对某些土样识别精度过高,对其他土样识别精度过低。因此,以绝对




图 8 所用神经网络的结构及其修改

Fig.8 The structure of the neutral networks and their modifications in this paper

a. 简单网络; b. NiN 修改; c. VGG16 修改; d. ResNet 系列修改




图9 基于CNN的含水率预测模型构建过程

Fig.9 Construction process of moisture content prediction model based on CNN

误差1%、3%、5%以内占比来评价模型识别结果.对单个样本,其预测绝对误差 ϵ 按下式计算:

$$\epsilon = |w_p - w_r|, \quad (2)$$

式中: w_p 为样本含水率预测值, w_r 为样本含水率真实值.

统计 N 个样本中 $\epsilon < 1\%$ 、 $\epsilon < 3\%$ 、 $\epsilon < 5\%$ 的样本个数,分别记为 n_1 、 n_2 、 n_3 .绝对误差 ϵ 以内占比 γ_ϵ 按下式计算:

$$\gamma_\epsilon = \sum_{j=1}^{\epsilon} \frac{n_j}{N} \times 100\%. \quad (3)$$

3 含水率预测模型效果评价

3.1 网络架构的影响分析

5种网络架构下模型的预测精度如图10所示.预测误差 $<1\%$ 的样本量占比中ResNet34最高,NiN次之,其余3种网络架构指标相近. $<3\%$ 、 $<5\%$ 的占比中ResNet34远高于其他4种网络架构,且四者指标无明显差异.这表明在基于图像的含水率预测问题上,简单网络、VGG16、NiN以及ResNet18的识别能力相近,精度略低.ResNet34远胜于它们(Canziani *et al.*, 2016),这表明对于基于图像的含水率识别问题,该网络架构更为优越,故确定ResNet34为最优网络架构.

3.2 数据集构建方法的影响分析

为探究混合数据集、分离数据集对模型精度的影响,确定最后数据集划分方法,以ResNet34作为网络架构,保持训练过程超参数不变,进行模型训练.对分离数据集而言,不同种类土各得到一个含




图10 各模型识别结果对比

Fig.10 Comparison of identification results of each model

水率识别模型,需要各自识别,统一性较差.对混合数据集而言,只得到一个含水率识别模型,它能识别所有类型土,统一性较强.

两种数据集下所得模型精度对比如图11所示,基于分离数据集训练所得模型对每种土样的含水率预测值与真实值的各绝对误差范围占比皆高于在混合数据集训练所得模型.这表明在现有数据量下,不同土样表达含水率的个性占比高于共性,用一个模型识别所有类型的土虽可以实现但精度不高,应当对不同种类土各自训练含水率识别模型.

以ResNet34为网络架构、对每种土各自训练含水率识别模型,4种土样的识别结果如表6与图12所示.含水率预测值对真实值的拟合系数 R^2 为0.80,平均绝对误差为2.52%.其中,1%、3%、5%以内误差范围占比的平均值分别为:34.20%、72.12%、89.64%.平均误差较小,预测误差在3%以内的样本量约占四分之三,且单样本识别所耗时间在1 ms以下,这表明卷积神经网络能够实现土样含水率的实时无损识别,识别精度能够满足工程需求.

3.3 异常样本筛选与剔除

在机器学习中,一般把离群值看作异常样本,异常样本对模型的训练和学习存在很大的损害.为此,特通过数学方法来确定离群值的阈值.具体方法如下:首先定义样本量相对下降率 r_ϵ ,按下式计算:

$$r_\epsilon = \frac{\gamma_\epsilon - \gamma_{\epsilon-1}}{\gamma_{\epsilon-1}} \times 100\%, \quad (4)$$

式中, γ_ϵ 为预测误差 $\leq \epsilon$ 的样本量占比.

本文分别计算预测误差2%、3%、...,13%的样




图 11 分离数据集与混合数据集训练结果对比

Fig.11 Comparison of training results between separate and mixed datasets

a. 延庆粉质黏土; b. 兰州粉土; c. 青海粉质黏土; d. 标准砂

表 6 ResNet34 各土样识别结果 (%)

Table 6 Identification results (%) of soil samples based on ResNet34 model

土样类型	γ_1	γ_3	γ_5
延庆粉质黏土	32.55	70.83	86.98
兰州粉土	37.38	72.34	90.97
青海粉质黏土	31.37	70.99	88.80
标准砂	39.29	94.64	100

本量相对下降率,结果如图 13 所示.当误差增大至 10% 时 r_e 为最小值,10% 之后 r_e 再次上升,这表明预测误差 10% 以内的样本与 10% 以外的样本具有不同的数据分布规律,认为是离群值.因此,选取 9% 作为临界误差,大于此误差的定义为异常样本.

为分析异常样本产生原因,将预测误差超过 9% 的样本作为异常样本,将具有相同含水率标签的其他样本作为对比样本,通过比较异常样本与对比样本的图片差异,分析造成含水率预测误差过大的原因.个别样本的对比分析结果如表 7 所示,1 号




图 12 最优模型全土样含水率预测结果

Fig.12 Optimal model prediction results of all types soil moisture content

异常样本标记含水率远小于其对比样本,但图片颜色更深,可能是拍摄光线不良所致.2、3 号异常样本图片有黑色斑点或白色带痕,可能由于养护不佳,水分丢失或分布不均所致.4 号异常样本图片模糊,




图 13 去除异常样本前样本量相对下降率变化情况

Fig.13 Changes in the relative decline rate of sample size before removing abnormal samples

可能是拍摄时未完成对焦所致。

去除异常样本后重新训练,所得最终模型对各土样含水率预测结果如图 14 所示.拟合系数 R^2 由 0.80 提高至 0.91.平均绝对误差由 2.52% 减小到 2.0%,预测精度有较大改善.同时,预测误差在 1%、3%、5% 以内的样本量占比分别增加到 36.96%、75.15%、93.63%(如图 15 所示),这表明数




图 14 去除异常样本后预测结果

Fig.14 Prediction results after removing abnormal samples



据质量对模型精度具有较大影响,数据收集过程应十分谨慎,初步训练结束后去除异常样本也是十分必要的。

4 讨论

为了弥补传统烘干法含水率测量耗时较长(超过 24 h)、破坏土体孔隙结构两个方面局限性,特建立了基于图像的含水率快速识别方法。

表 7 异常样本及对比分析

Table 7 Abnormal samples and comparative analysis

土样编号	1	2	3	4
土样类型	延庆粉质黏土	青海粉质黏土	兰州粉土	兰州粉土
异常样本				
	预测值:26.55%	预测值:16.23%	预测值:14.68%	预测值:22.35%
	真实值:9.05%	真实值:25.95%	真实值:26.20%	真实值:31.85%
对比样本				
	预测值:11.79%	预测值:25.39%	预测值:25.18%	预测值:27.76%
	真实值:9.05%	真实值:25.95%	真实值:26.20%	真实值:31.85%




图15 去除异常样本前后识别效果对比

Fig.15 Comparison of identification effect before and after removing abnormal samples

从理论上讲,土体含水率发生变化,其表面照片的明暗、颜色、纹理等特征都会发生变化.曾有一些研究通过人工提取颜色等特征,然后建立这些特征和含水率之间的定量关系模型(Persson, 2005; McBratney *et al.*, 2006).然而含水率对土样照片特征的影响机理复杂,影响因素众多,因此这些定量模型精度不高,并且模型泛化能力较差.

由于CNN具有超强的图像特征提取的优点,特采用CNN构建基于图像的含水率识别模型.基于CNN的含水率识别方法无需人工提取颜色等特征(张晗等, 2023),以原图像作为输入,保留了土样的全部信息,为模型识别含水率提供了信息基础.

在实际工程应用中,可以拍摄土样照片,将其送入模型,实时获得土样的含水率.该方法能够基于土样表面照片,在毫秒时间内实现土样含水率的测量快速无损检测.随着岩土工程智能建造的快速发展,该模型将是现场含水率快速无损检测或监测的重要手段,成为传统烘干法之外的一种高效补充手段.

需要指出的是,该研究现阶段还存在以下问题需要进一步解决:

(1)基于现有数据,对不同类型土训练统一含水率识别模型的做法并不如针对不同种类土各自训练识别模型,原因可能是样本量过少无法满足依赖大数据的CNN,因此有必要进一步增加不同类型、不同压实度的土,并进一步缩短拍摄时间间隔以捕捉更细致的含水

率变化,探究统一含水率识别模型的可能性.

(2)目前所采用土样是在实验室中收集得到的,土样表面较为平整,噪音较少.实际工程中有待识别的土样往往受到诸多环境因素的干扰,如现场的光照更为强烈、粗糙的采样方法会导致土样表面凹凸不平等.实际土样的统计学分布与模型训练所用土样存在较大差异,会导致模型无法直接应用.鉴于重新训练基于CNN的模型需要大量数据,工程中往往不能满足.针对此类问题,一个可行的做法是采取迁移学习(Yi *et al.*, 2022; Dawson *et al.*, 2023),即在工程现场再收集少量实际土样,将其加入现有数据集,在已有模型的基础上再次进行训练.

简而言之,样本是图像识别模型的基础和关键.应根据实际工程需求加入合适的样本对模型进行进一步的训练和优化,随着样本多样性和数量的进一步增加,含水率识别模型的精度有望进一步提高.

5 结论

针对传统方法耗时低效以及现有机器学习方法特征提取过程繁琐的问题,基于卷积神经网络提出一种含水率快速识别方法.首先收集了4种土样在不同含水率下的表面图像,以不同数据集划分方法建立了两种含水率数据集.通过比较不同模型在同一数据集的识别结果以及同一模型在不同数据集的识别结果,确定最优模型以及最优数据集划分方法,最后剔除异常数据得到含水率智能识别模型.主要结论如下:

(1)不同数据集划分方法对含水率识别结果具有较大影响,不同土样表现含水率的特征也不尽相同,用一种模型识别所有土样是不合理的,针对不同的土样应当采用不同的含水率识别模型.

(2)不同模型的含水率识别结果有较大差异,含水率特征有一定复杂度,应选用与之相匹配的网络架构.就同一种网络架构而言,其不同土样的识别效果是同时改善的,不同土样表现含水率的特征有相似之处.

(3)含水率识别精度最高的是以ResNet34为网络架构训练的模型,剔除坏数据后,含水率预测值与真实值绝对误差

在 1%、3%、5% 以内的样本量占比分别为 35%、75% 和 90%，平均绝对误差为 2.0%。

References

- Cai, Y., Zheng, W. G., Zhang, X., et al., 2019. Research on Soil Moisture Prediction Model Based on Deep Learning. *PLoS One*, 14(4): e0214508. <https://doi.org/10.1371/journal.pone.0214508>
- Canziani, A., Paszke, A., Culurciello, E., 2016. An Analysis of Deep Neural Network Models for Practical Applications. ArXiv, abs/1605.07678. <https://doi.org/10.48550/arXiv.1605.07678>
- Chang, D., Li, X., Liu, J.K., et al., 2014. Study Progress and Comparison of Soil Moisture Content Measurement Methods. *Geotechnical Investigation & Surveying*, 42(9): 17–22, 35 (in Chinese with English abstract).
- Chen, T. Q., Moreau, T., Jiang, Z. H., et al., 2018. TVM: An Automated End-to-End Optimizing Compiler for Deep Learning. ArXiv, 1802.04799. <http://arxiv.org/abs/1802.04799.pdf>
- Cheng, G.J., Li, B., Wan, X.L., et al., 2021. Research on Classification of Rock Section Image Based on Squeezenet Convolutional Neural Network. *Mineralogy and Petrology*, 41(4): 94–101 (in Chinese with English abstract).
- Dawson, H. L., Dubrule, O., John, C. M., 2023. Impact of Dataset Size and Convolutional Neural Network Architecture on Transfer Learning for Carbonate Rock Classification. *Computers & Geosciences*, 171: 105284. <https://doi.org/10.1016/j.cageo.2022.105284>
- Domínguez-Cuesta, M. J., Quintana, L., Valenzuela, P., et al., 2021. Evolution of a Human-Induced Mass Movement under the Influence of Rainfall and Soil Moisture. *Landslides*, 18(11): 3685–3693. <https://doi.org/10.1007/s10346-021-01731-4>
- Fan, H. Y., Tian, Z. H., Xu, X. B., et al., 2022. Rock-fill Material Segmentation and Gradation Calculation Based on Deep Learning. *Case Studies in Construction Materials*, 17: e01216. <https://doi.org/10.1016/j.cscm.2022.e01216>
- Guo, T., Yu, H.B., 2018. Methods of Determination of Soil Water Content. *Inner Mongolia Science Technology & Economy*, (3): 66–67 (in Chinese with English abstract).
- He, K. M., Zhang, X. Y., Ren, S. Q., et al., 2016. Deep Residual Learning for Image Recognition. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, Las Vegas, 770–778. <https://doi.org/10.1109/CVPR.2016.90>
- Hou, X.L., Feng, Y.H., Wu, G.H., et al., 2016. Application Research on Artificial Neural Network Dynamic Prediction Model of Soil Moisture. *Water Saving Irrigation*, (7): 70–72, 76 (in Chinese with English abstract).
- Huang, G., Liu, Z., Laurens, V., et al., 2016. Densely Connected Convolutional Networks. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, 2261–2269. <https://doi.org/10.1109/CVPR.2017.243>
- Huang, W.B., Ding, M.T., Wang, D., et al., 2022. Evaluation of Landslide Susceptibility Based on Layer Adaptive Weighted Convolutional Neural Network Model along Sichuan-Tibet Traffic Corridor. *Earth Science*, 47(6): 2015–2030 (in Chinese with English abstract).
- Huang, X.H., Li, T.F., Liu, X.X., et al., 2022. Research on Tracking and Prediction of Rock Fissure Sevelopment Based on Improved Faster R-CNN Algorithm. *Journal of Henan Polytechnic University (Natural Science)*, 41(4): 134–141 (in Chinese with English abstract).
- Krizhevsky, A., Sutskever, I., Hinton, G. E., 2017. ImageNet Classification with Deep Convolutional Neural Networks. *Communications of the ACM*, 60(6): 84–90. <https://doi.org/10.1145/3065386>
- Lin, M., Chen, Q., Yan, S. C., 2014. Network in Network. ArXiv Preprint ArXiv, 1312.4400. <https://doi.org/10.48550/arXiv.1312.4400>
- McBratney, A. B., Minasny, B., Viscarra Rossel, R., 2006. Spectral Soil Analysis and Inference Systems: A Powerful Combination for Solving the Soil Data Crisis. *Geoderma*, 136(1/2): 272–278. <https://doi.org/10.1016/j.geoderma.2006.03.051>
- Ni, J.P., Gao, M., Wei, C.F., et al., 2009. Effects of Soil Water Content on Soil Shearing Strength to Different Soil Layer of Shallow Landslide. *Journal of Soil and Water Conservation*, 23(6): 48–50 (in Chinese with English abstract).
- Persson, M., 2005. Estimating Surface Soil Moisture from Soil Color Using Image Analysis. *Vadose Zone Journal*, 4(4): 1119–1122. <https://doi.org/10.2136/vzj2005.0023>
- Simonyan, K., Zisserman, A., 2015. Very Deep Convolutional Networks for Large-Scale Image Recognition. International Conference on Learning Representations (ICLR), San Diego, 1–14. <https://doi.org/10.48550/arXiv.1409.1556>
- Song, B.H., Chen, W.W., Wu, W.J., et al., 2017. Experi-

- mental Study on the Dynamic Properties of Sliding Zone Soil of a Landslide under Varying Water Content. *China Earthquake Engineering Journal*, 39(4): 744—749, 758 (in Chinese with English abstract).
- Sun, Y. L., Qu, Z. Y., Liu, Q. M., et al., 2020. Dynamic Study of Regional Soil Moisture Content Based on Multi-Source Remote Sensing Co-Inversion. *Journal of Southwest University (Natural Science Edition)*, 42(12): 46—53 (in Chinese with English abstract).
- Szegedy, C., Liu, W., Jia, Y., et al., 2015. Going Deeper with Convolutions. The IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Chicago, 1—9. <https://doi.org/10.48550/arXiv.1409.4842>
- Tian, X., Daigle, H., 2018. Machine-Learning-Based Object Detection in Images for Reservoir Characterization: A Case Study of Fracture Detection in Shales. *The Leading Edge*, 37(6): 435—442. <https://doi.org/10.1190/tle37060435.1>
- Wang, D. L., Shu, Y. G., 2017. Research Progress in Determination Methods for Soil Water Content. *Journal of Mountain Agriculture and Biology*, 36(2): 61—65 (in Chinese with English abstract).
- Wang, M., Li, X., Chen, L. H., et al., 2020. A Modified Soil Water Content Measurement Technique Using Actively Heated Fiber Optic Sensor. *Journal of Rock Mechanics and Geotechnical Engineering*, 12(3): 608—619. <https://doi.org/10.1016/j.jrmge.2019.11.003>
- Wang, Z. L., Wang, X. Y., Sun, L., 2012. Research of Variation Laws of Shear Strength between Invaded and Natural Collapsible Loess—A Case Study for Collapsible Loess in Gongyi of Henan. *South-to-North Water Diversion and Water Science & Technology*, 10(3): 123—126 (in Chinese with English abstract).
- Yao, L., Wang, Y. R., Chen, Z., et al., 2020. Time-Varying Characteristics of Spatial Variability of Soil Moisture Content in Farmland. *Water Saving Irrigation*, (3): 33—39 (in Chinese with English abstract).
- Yi, X. F., Li, H., Zhang, R. C., et al., 2022. Rock Mass Structural Surface Trace Extraction Based on Transfer Learning. *Open Geosciences*, 14(1): 98—110. <https://doi.org/10.1515/geo-2022-0337>
- Yu, D. C., Ding, P., Yang, Z. Q., et al., 2021. Study on the Influence of Initial Water Content on the Breakout of Loess Landslide Barrier Dam. *Mountain Research*, 39(3): 367—377 (in Chinese with English abstract).
- Zanetti, S. S., Cecilio, R. A., Alves, E. G., et al., 2015. Estimation of the Moisture Content of Tropical Soils Using Colour Images and Artificial Neural Networks. *CATENA*, 135: 100—106. <https://doi.org/10.1016/j.catena.2015.07.015>
- Zhang, H., Wei, W. L., Liu, S. S., et al., 2023. Intelligent Identification Method of Moisture Content of Loess Based on Transfer Convolutional Neural Networks. *Journal of Engineering Geology*, 31(1): 21—31 (in Chinese with English abstract).
- Zhao, N. Y., Jiang, Y., Song, Y., 2021. Recognition and Classification of Concrete Cracks under Strong Interference Based on Convolutional Neural Network. *Traitements Du Signal*, 38(3): 911—917. <https://doi.org/10.18280/ts.380338>
- Zhao, Y. F., Wang, C. S., 2017. Principles and Comparison of Common Methods for Determining Soil Water Content. *Horticulture & Seed*, 37(10): 70—73 (in Chinese with English abstract).
- Zheng, Z. W., Gao, Z. Z., 2020. Research on Influence of Soil Moisture Content of Farmland on Infiltration Model Parameters. *E3S Web of Conferences*, 189(3): 01011. <https://doi.org/10.1051/e3sconf/202018901011>
- Zhou, C., Hu, G. L., Deng, L. Y., et al., 2021. Variation Characteristics of Soil Organic Matter and Water Content in Different Types of Landscape in the Middle Reaches of Heihe River. *Journal of Gansu Agricultural University*, 56(4): 126—135 (in Chinese with English abstract).
- Zhou, S. G., 2007. Main Geology Disasters Type of Loess Tunnel. *Geology and Prospecting*, 43(2): 103—107 (in Chinese with English abstract).

中文参考文献

- 常丹, 李旭, 刘建坤, 等, 2014. 土体含水率测量方法研究进展及比较. *工程勘察*, 42(9): 17—22, 35.
- 程国建, 李碧, 万晓龙, 等, 2021. 基于 SqueezeNet 卷积神经网络的岩石薄片图像分类研究. *矿物岩石*, 41(4): 94—101.
- 郭焘, 于红博, 2018. 土壤含水量测定方法综述. *内蒙古科技与经济*, (3): 66—67.
- 侯晓丽, 冯跃华, 吴光辉, 等, 2016. 基于人工神经网络土壤墒情动态预测模型应用研究. *节水灌溉*, (7): 70—72, 76.
- 黄武彪, 丁明涛, 王栋, 等, 2022. 基于层数自适应加权卷积神经网络的川藏交通廊道沿线滑坡易发性评价. *地球科学*, 47(6): 2015—2030.
- 黄晓红, 李铁锋, 刘祥鑫, 等, 2022. 基于改进 Faster R-CNN 算法的岩石裂隙发展方向跟踪预测研究. *河南理工大学学报(自然科学版)*, 41(4): 134—141.

- 倪九派, 高明, 魏朝富, 等, 2009. 土壤含水率对浅层滑坡体不同层次土壤抗剪强度的影响. 水土保持学报, 23(6): 48—50.
- 宋丙辉, 湛文武, 吴玮江, 等, 2017. 不同含水率下滑坡滑带土动力特性试验研究. 地震工程学报, 39(4): 744—749, 758.
- 孙宇乐, 屈忠义, 刘全明, 等, 2020. 基于多源遥感协同反演的区域性土壤含水率动态研究. 西南大学学报(自然科学版), 42(12): 46—53.
- 王大龙, 舒英格, 2017. 土壤含水量测定方法研究进展. 山地农业生物学报, 36(2): 61—65.
- 王志良, 王秀艳, 孙琳, 2012. 湿陷性黄土浸水前后抗剪强度变化规律研究: 以河南巩义地区湿陷性黄土为例. 南水北调与水利科技, 10(3): 123—126.
- 姚丽, 王仰仁, 陈钊, 等, 2020. 农田土壤含水率空间变异的时变特性研究. 节水灌溉, (3): 33—39.
- 雨德聪, 丁攀, 杨志全, 等, 2021. 初始含水率对黄土滑坡堰塞坝溃决影响研究. 山地学报, 39(3): 367—377.
- 张晗, 魏文龙, 刘森森, 等, 2023. 基于迁移卷积神经网络的黄土含水率智能识别. 工程地质学报, 31(1): 21—31.
- 赵宇飞, 王长沙, 2017. 常用土壤含水量测定方法的原理及比较. 园艺与种苗, 37(10): 70—73.
- 周川, 胡广录, 邓丽媛, 等, 2021. 黑河中游不同景观类型土壤有机质与含水率变化特征. 甘肃农业大学学报, 56(4): 126—135.
- 周尚国, 2007. 黄土隧道的主要地质灾害类型. 地质与勘探, 43(2): 103—107.

《地球科学》

2024年6月 第49卷 第6期 要目预告

- 秦岭生态地质环境系统本底特征及研究体系初步构想·····申艳军等
- 大陆深部地壳脱水熔融与水致熔融的演化特征及其流变学意义·····陶丽蓉等
- 库车坳陷侏罗系致密砂岩气藏“三品质”测井评价·····信 毅等
- 广西离子吸附型重稀土找矿突破方向研究与科研性示范勘查进展·····付 伟等
- 火星水冰分布特征和研究进展·····刘正豪等
- 地质温度计在桂东南那卜韧性剪切带花岗质糜棱岩中的适用性·····辛良伟等
- 黄河形成于何时? ·····林 旭等